

Clasificación géneros de películas utilizando el cartel publicitario mediante aprendizaje profundo

Claudia Lissette Gutiérrez Díaz¹

Palabras Clave

Películas, Clasificación de géneros, Aprendizaje Profundo, Métodos convolucionales

Fecha: 10 de abril de 2024

¹Lic. Ciencias Computacionales, Facultad de Ciencias Físico - Matemáticas, UANL

Índice

1	Introducción	1
2	Trabajo relacionado	2
3	Conjunto de datos y características	2
3.1	Descarga de información	2
3.2	Preprocesamiento	2
4	Metodologías y mediciones	3
4.1	Métodos empleados	4
4.2	Función de pérdida	4
4.3	Métricas	5
5	Experimentación y resultados	5
6	Conclusión	7

1. Introducción

En la actualidad, el mundo del cine despliega un papel fundamental en el panorama del entretenimiento, ofreciendo a las audiencias una amplia gama de opciones para acceder a películas. Desde las tradicionales salas de cine hasta los formatos más modernos como DVD, Blue ray y las diversas plataformas de streaming como Netflix, Max, Prime Video o Disney+, el acceso a la cinematografía se ha vuelto más accesible que nunca gracias al internet y la evolución tecnológica del siglo XXI.


Uno de los elementos clave para atraer y cautivar a un público específico es el póster cinematográfico. Este arte visual representa uno de los primeros encuentros que el público tiene con una película, ya sea al pasar por la entrada de un cine o al explorar el catálogo de una plataforma de streaming como Netflix. Por consiguiente, para la industria del cine, resulta fundamental que la imagen del póster pueda transmitir de manera efectiva el género y la esencia de la película a la audiencia.

Tomando en cuenta este fenómeno, podemos suponer la información relevante para determinar el género. Pueden ser características de bajo nivel como el color predominante, la estructura espacial, texturas, etc. (Potter, 1976).

El objetivo de este estudio es poder determinar el o los géneros que componen una película por analizar las características de su póster.

La información de las películas, la hemos obtenido mediante la API de OMDB (OMDb API, 2024).

En este artículo abordaremos información relacionada a la clasificación de películas, las estrategias que seguiremos para ejecutar el modelo de entrenamiento y prueba y compararemos el resultado de nuestro método contra la realidad. Consideremos que este problema abordará la multi-etiqueta de género, como en la figura 1, es decir, que una sola película puede pertenecer a más de un género.



Animation
Adventure
Drama

Figura 1. Ejemplo de multi-etiqueta de películas

2. Trabajo relacionado

Durante los años, ha habido intentos en la predicción de género utilizando imágenes. Wehrmann y Barros utilizaron redes neuronales convolucionales para realizar clasificación de género multi-etiqueta a partir de avances de películas (Wehrmann & Barros, 2017). Esto muestra esfuerzos para identificar el género de una película en función de elementos visuales. El estudio encontró que el uso de CNN superó a los métodos preexistentes de clasificación de género, como la limitación de características (Barney & Kaya, 2019).

3. Conjunto de datos y características

3.1 Descarga de información

Creamos nuestro conjunto de datos a partir de la página OMDb, el cual almacena millones de registros de películas, series y cortos con sus características principales, incluyendo el link con el poster. Realizamos un ciclo de filtrado inicial para, obtener aquellos registros que cumplieran con las siguientes características:

- El registro tiene que ser una película, descartando otro tipo de entretenimiento como las series.
- En el intento por evitar aquellas películas cuyo poster está en blanco y negro, la película debe haber salido después de 1970.
- Se descartan géneros que consideramos no aportan a los motivos de este artículo: *Adult, Documentary, Short, Biography*.
- La película debe estar en idioma inglés.
- La película debe tener un link del poster.

Se utilizó la API proporcionada por la página para realizar la descarga. Se consultaron más de 4 millones de registros, de los cuales, con los filtros antes mencionados, se obtuvieron 127,419 opciones aceptables en primera instancia.

3.2 Preprocesamiento

Observando los registros filtrados, hay géneros que no contemplamos en el primer filtro y que consideramos no van a aportar al proyecto, así como géneros con muestra muy reducida que podría desbalancear los pesos. Aplicamos un segundo filtro con las siguientes características:

- Se quitaron registros duplicados.
- Se descartaron los siguientes géneros: *Game-Show, News, Reality-TV, Talk-Show, Western, History, Musical, War*.

Una vez aplicados los filtros, de 127,419 registros, quedaron 48,139. Lo siguiente que se realizó fue proceder a la lectura de los links de los posters e ir guardando cada imagen en formato “(imdbID).jpg”. Hubo links que no funcionaban, por lo que de los 48,139 registros, quedó finalmente una muestra de **47,756**.

Para una de las estrategias de modelado de la red neuronal, de la cual hablaremos más adelante, usamos el *Oversampling*, con el que se redujo el tamaño de la muestra para lograr un balance, el cual quedó con una cantidad de **21,730**. El cuadro 1, presenta la distribución final de cada género, tanto originalmente como aplicando el Oversampling.

Cuadro 1. Distribución de géneros.

Género	Original	% Original	Oversampling	% Oversampling
Action	7,141	8.05 %	3,954	9.64 %
Adventure	3,900	4.39 %	3,144	7.67 %
Animation	1,622	1.83 %	2,019	4.92 %
Comedy	14,358	16.18 %	2,276	5.55 %
Crime	5,755	6.48 %	2,245	5.48 %
Drama	22,302	25.13 %	3,556	8.67 %
Family	2,730	3.08 %	3,916	9.55 %
Fantasy	2,293	2.58 %	2,156	5.26 %
Horror	6,521	7.35 %	3,092	7.54 %
Music	2,204	2.48 %	2,102	5.13 %
Mystery	3,062	3.45 %	2,397	5.85 %
Romance	5,020	5.66 %	1,820	4.44 %
Sci-Fi	2,881	3.25 %	1,946	4.75 %
Sport	1,471	1.66 %	3,231	7.88 %
Thriller	7,489	8.44 %	3,146	7.67 %

4. Metodologías y mediciones

La red neuronal convolucional (ConvNet/CNN) es uno de los algoritmos de aprendizaje profundo el cual puede tomar como entrada una imagen, asignarle importancia a varias características de la imagen y permitirle diferenciar una de otras (Prasanna et al., 2021). Las redes convolucionales que utilizaremos constarán de las siguientes capas:

- **Capa convolucional:** Esta capa crea un kernel que convoluciona con la capa de entrada en una única dimensión espacial (o temporal) para producir un tensor de salidas. Le da un significado a la imagen que recibe. En todos los métodos definidos usaremos una dimensión de (3, 3). Todas las capas utilizadas en todos los métodos usarán la función de activación ReLU, para que mantenga valores positivos.
- **Max Pooling:** Desmuestra la entrada a lo largo de sus dimensiones espaciales tomando el valor máximo en una ventana de entrada, que en nuestro caso y para todos los métodos definidos usaremos una dimensión de (2, 2), para cada canal de entrada. La ventana se desplaza por pasos a lo largo de cada dimensión.
- **Normalización por lotes:** Aplica una transformación que mantiene la media de salida cercana a 0 y la desviación estándar de salida cercana a 1. Durante el entrenamiento, la capa normaliza su salida utilizando la media y la desviación estándar del lote actual de entradas. Esta capa no estará en todos nuestros métodos, puesto que es un caso de prueba donde probaremos la efectividad de normalizar los datos entre capa y capa para acelerar y mejorar la precisión (Ioffe & Szegedy, 2015)
- **Dropout:** Pone aleatoriamente 0 a las unidades de entrada con una frecuencia de tasa en cada paso durante el tiempo de entrenamiento, lo que ayuda a evitar un sobreajuste. Esta capa no estará en todos nuestros métodos, puesto que es un caso de prueba donde probaremos la efectividad de aplicar esta capa y así evitar el sobre ajuste. Para los métodos donde la usemos usaremos una tasa de 0.3.
- **Flatten:** Aplana la entrada para poder aplicar una red neuronal simple.
- **Dense:** Capa normal de red neuronal con la aplicación de sus pesos y función de activación. Todas las capas previas a la de salida tendrán la función de activación ReLU, para mantener números positivos. La capa de salida tendrá la función Sigmoid, para mantener un valor entre 0 y 1, donde entre más cercano a 1, es más probable que pertenezca a ese género.

En este estudio, consideraremos una salida multi-etiqueta, donde una imagen puede pertenecer a 1 o más categorías, y las probabilidades más cercanas a 1, indicarán que pertenece a esta categoría. Al final de cada método, se hará el redondeo a 1,

de acuerdo a la probabilidad que establezcamos como umbral. Para este caso, haremos evaluaciones donde se tomará como 1 cuando la probabilidad sea mayor al 30 %, 40 % y 50 %.

Para algunos métodos usaremos una muestra con *Oversampling*, el cual realiza repetición de ciertas categorías desbalanceadas, para tratar de igualar los porcentajes entre cada una de las etiquetas y así asegurar un mejor entrenamiento.

4.1 Métodos empleados

Para este estudio, utilizaremos la librería *Tensorflow* de Python para realizar la comparación métodos. A pesar de que en los 4 métodos usaremos CNN, habrá diferentes modificaciones entre estos para determinar cuál es más efectivo para nuestro caso de estudio.

1. **Método 1:** Para este método usaremos una arquitectura de 4 capas convolucionales, 4 capas de pooling, 1 capa de flatten y 3 capas de red neuronal artificial y como entrada serán los datos originales sin balanceo, usando aleatoriamente el 80 % de los datos para entrenar. El cuadro 2 muestra con más detalle la arquitectura de la CNN. Usaremos un tamaño de batch de 20 y 15 epoch.
2. **Método 2:** Para este método usaremos una arquitectura de 4 capas convolucionales, 4 capas de pooling, 1 capa de flatten y 3 capas de red neuronal artificial y como entrada serán los datos con oversampling, usando aleatoriamente el 80 % de los datos para entrenar. El cuadro 2 muestra con más detalle la arquitectura de la CNN. Usaremos un tamaño de batch de 20 y 15 epoch.
3. **Método 3:** Para este método usaremos una arquitectura de 4 capas convolucionales, 4 capas de pooling, 6 capas de normalización, 6 capas de dropout, 1 capa de flatten y 3 de red neuronal artificial y como entrada serán los datos originales sin balanceo, usando aleatoriamente el 80 % de los datos para entrenar. El cuadro 3 muestra con más detalle la arquitectura de la CNN. Usaremos un tamaño de batch de 25 y 15 epoch. Entre cada epoch, ajustaremos la tasa de aprendizaje si es necesario y evaluaremos detener tempranamente el entrenamiento para evitar el sobreajuste.
4. **Método 4:** Para este método usaremos una arquitectura de 4 capas convolucionales, 4 capas de pooling, 6 capas de normalización, 6 capas de dropout, 1 capa de flatten y 3 de red neuronal artificial y como entrada serán los datos con oversampling, usando aleatoriamente el 80 % de los datos para entrenar. El cuadro 3 muestra con más detalle la arquitectura de la CNN. Usaremos un tamaño de batch de 25 y 15 epoch. Entre cada epoch, ajustaremos la tasa de aprendizaje si es necesario y evaluaremos detener tempranamente el entrenamiento para evitar el sobreajuste.

Cuadro 2. Arquitectura CNN para métodos 1 y 2

Nombre capa	Tipo capa	Salida	Función Activación
conv2d_0	(Conv2d)	(248, 248, 16)	ReLU
max_pooling2d_0	(MaxPooling2D)	(124, 124, 16)	
conv2d_1	(Conv2d)	(122, 122, 32)	ReLU
max_pooling2d_1	(MaxPooling2D)	(61, 61, 32)	
conv2d_2	(Conv2d)	(59, 59, 64)	ReLU
max_pooling2d_2	(MaxPooling2D)	(29, 29, 64)	
conv2d_3	(Conv2d)	(27, 27, 128)	ReLU
max_pooling2d_3	(MaxPooling2D)	(13, 13, 128)	
flatten	(Flatten)	21,632	
dense_0	(Dense)	64	ReLU
dense_1	(Dense)	128	ReLU
dense_2	(Dense)	15	Sigmoid

4.2 Función de pérdida

Para los 4 métodos usaremos la función de pérdida *Binary Cross-entropy*, el cual cuantifica la disimilitud entre las distribuciones de probabilidad, ayudando en el entrenamiento del modelo al penalizar las predicciones inexactas.

$$Logloss = \frac{1}{N} \sum_{i=1}^N -(y_i * \log(p_i) + (1 - y_i) * \log(1 - p_i)) \quad (1)$$

Iremos ajustando los pesos mediante la propagación hacia atrás usando el gradiente descendiente con una tasa de aprendizaje inicial de 0.01.

Cuadro 3. Arquitectura CNN para métodos 1 y 2

Nombre capa	Tipo capa	Salida	Función Activación
conv2d_0	(Conv2d)	(248, 248, 16)	ReLU
batch_normalization_0	(BatchNormalization)	(248, 248, 16)	
max_pooling2d_0	(MaxPooling2D)	(124, 124, 16)	
dropout_0	(Dropout)	(124, 124, 16)	
conv2d_1	(Conv2d)	(122, 122, 32)	ReLU
batch_normalization_1	(BatchNormalization)	(122, 122, 32)	
max_pooling2d_1	(MaxPooling2D)	(61, 61, 32)	
dropout_1	(Dropout)	(61, 61, 32)	
conv2d_2	(Conv2d)	(59, 59, 64)	ReLU
batch_normalization_2	(BatchNormalization)	(59, 59, 64)	
max_pooling2d_2	(MaxPooling2D)	(29, 29, 64)	
dropout_2	(Dropout)	(29, 29, 64)	
conv2d_3	(Conv2d)	(27, 27, 128)	ReLU
batch_normalization_3	(BatchNormalization)	(27, 27, 128)	
max_pooling2d_3	(MaxPooling2D)	(13, 13, 128)	
dropout_3	(Dropout)	(13, 13, 128)	
flatten	(Flatten)	21,632	ReLU
dense_0	(Dense)	64	
batch_normalization_4	(BatchNormalization)	64	
dropout_4	(Dropout)	64	
dense_1	(Dense)	128	ReLU
batch_normalization_5	(BatchNormalization)	128	
dropout_5	(Dropout)	128	
dense_2	(Dense)	15	Sigmoid

4.3 Métricas

Para los 4 modelos usaremos las siguientes métricas

- **Accuracy_score:** Calcula la precisión del subconjunto. Si el conjunto completo de etiquetas predichas para una muestra coincide estrictamente con el conjunto verdadero de etiquetas, entonces la precisión del subconjunto es 1, en caso contrario, es 0.
- **Precision_score:** Calcula la precisión con la relación $tp/(tp + fp)$ donde tp es el número de verdaderos positivos y fp el número de falsos positivos. La precisión es intuitivamente la capacidad del clasificador para no etiquetar como positiva una muestra que es negativa. El mejor valor es 1 y el peor 0. El promedio *micro*, calcula las métricas globalmente contando el total de verdaderos positivos, falsos negativos y falsos positivos.
- **Recall_score:** Es la relación $tp/(tp + fn)$, donde tp es el número de verdaderos positivos y fn es el número de falsos negativos. Es la capacidad del clasificador para encontrar todas las muestras positivas. El mejor valor es 1 y el peor 0. El promedio *micro*, calcula las métricas globalmente contando el total de verdaderos positivos, falsos negativos y falsos positivos.
- **F1_score:** Puede interpretarse como una media armónica de la precisión y la recuperación, donde la puntuación F1 alcanza su mejor valor en 1 y la peor puntuación en 0. La contribución relativa de la precisión y la recuperación a la puntuación F1 son iguales. Está dada por la fórmula $F1 = (2 * tp) / (2 * tp + fp + fn)$, donde tp es el número de verdaderos positivos, fn es el número de falsos negativos y fp es el número de falsos positivos. El promedio *micro*, calcula las métricas globalmente contando el total de verdaderos positivos, falsos negativos y falsos positivos.

5. Experimentación y resultados

Una vez definidos los 4 métodos que se usarán para la comparativa, se crearon los modelos secuenciales de acuerdo a las arquitecturas y muestras especificadas y se ejecutaron por separado. Considerar que para replicar este experimento se necesita una RAM de 64GB.

Cuadro 4. Comparativa de las métricas entre los 4 métodos experimentales

Método	Umbral	Accuracy	Precision	Recall	F1
Método 1	30 %	0.07	0.33	0.36	0.34
Método 1	40 %	0.08	0.34	0.32	0.33
Método 1	50 %	0.09	0.35	0.28	0.31
Método 2	30 %	0.54	0.70	0.67	0.69
Método 2	40 %	0.55	0.72	0.66	0.69
Método 2	50 %	0.55	0.73	0.65	0.69
Método 3	30 %	0.13	0.45	0.40	0.42
Método 3	40 %	0.16	0.52	0.29	0.37
Método 3	50 %	0.14	0.56	0.21	0.31
Método 4	30 %	0.30	0.55	0.53	0.54
Método 4	40 %	0.31	0.66	0.44	0.52
Método 4	50 %	0.27	0.77	0.35	0.48

En la tabla 4 se presentan los resultados de las métricas obtenidas mediante la aplicación de diferentes métodos. Hemos resaltado las filas ganadoras de cada métrica para facilitar su lectura. Se observa una mayor concentración de victorias en el Método 2, lo que lo posiciona como el ganador. Este método consiste en la aplicación de capas sin normalización ni dropout, junto con un oversampling para equilibrar las etiquetas. Observando los umbrales, también vemos una mayor concentración de ganadores al emplear el 40 % o 50 % de la probabilidad.


Para una mejor comprensión, en las figuras 2 y 3 se muestra un ejemplo aleatorio de una predicción comparada con su correspondiente realidad.



Método 1

Original: Drama, Mystery, Sci-Fi

Predicción: Horror, Music




Método 2

Original: Adventure, Family, Fantasy

Predicción: Adventure, Family,
Fantasy


Figura 2. Ejemplo de resultados entre lo real y la predicción para los métodos 1 y 2



Método 3

Original: Horror, Thriller

Predicción: Drama



Método 4

Original: Family

Predicción: Family

Figura 3. Ejemplo de resultados entre lo real y la predicción para los métodos 3 y 4

6. Conclusión

Basándonos en la evaluación de las cuatro estrategias de la CNN implementadas en este estudio, se puede concluir la importancia crucial de aplicar un equilibrio adecuado entre los registros. En las comparaciones entre el método 1 y 2, así como entre el método 3 y 4, los ganadores resultaron ser aquellos que emplearon la técnica de *Oversampling*, evidenciando una marcada disparidad en las métricas en comparación con los métodos que utilizaron la muestra original sin balance.

Asimismo, al contrastar el método 2 y 4, ambos empleando *Oversampling*, pero con la adición de capas de normalización y dropout en el método 4, se observó que estas capas extras tuvieron un efecto adverso. Se pudo notar, mediante el seguimiento del ciclo epoch tras epoch, que los valores estaban propensos al sobreajuste, evidenciado por la pérdida de precisión (*accuracy*) conforme avanzaban los epochs.

También, se puede dar el supuesto de que los errores de predicción, sean debido a un mal diseño de poster, donde humanamente, no representa la categoría que uno supondría a simple vista.

Como sugerencia de mejora, se podría considerar elevar la calidad de las imágenes, aun cuando esto implique un mayor consumo de recursos para el modelado. Además, sería beneficioso reducir la cantidad de géneros a categorías más diferenciadas. Por ejemplo, *Horror* y *Thriller* son géneros que presentan similitudes significativas al observar los pósters, y lo mismo ocurre con *Comedy* y *Family*.

Referencias

- Barney, G., & Kaya, K. (2019). Predicting genre from movie posters. *Stanford CS 229: Machine Learning*.
- Ioffe, S., & Szegedy, C. (2015, julio). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. En F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448-456, Vol. 37). PMLR. <https://proceedings.mlr.press/v37/ioffe15.html>

- OMDb API. (2024). *OMDb API*. <http://www.omdbapi.com>
- Potter, M. (1976). Short-term conceptual memory for pictures. *Journal of Experimental Psychology: Human Learning and Memory* 2. 5, 509.
- Prasanna, N., Vaishnavi, R., Lakshmi, V., Dakshayani, V., & Keerthana, T. (2021). Multi label classification for an image using convolutional neural networks. *Int. J. Comput. Sci. Mobile Comput.*, 10, 1-9.
- Wehrmann, J., & Barros, R. C. (2017). Convolutions through Time for Multi-label Movie Genre Classification. *Proceedings of the Symposium on Applied Computing*, 114-119.